

```
# Importowanie potrzebnych bibliotek
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import scipy.stats as stats
from scipy.stats import gaussian_kde
from scipy.stats import kstest, anderson
from scipy.stats import skew, kurtosis
from scipy.stats import gamma, lognorm, pareto
```

1 Plik

```
# Ścieżka do pliku CSV
file_path = "C:/Users/Lukasz/Desktop/studia/Semestr 7/insurance.csv"

# Wczytywanie danych z pliku CSV
try:
    data = pd.read_csv(file_path)
    print("Dane zostały pomyślnie wczytane.")
    print(data.head())
except FileNotFoundError:
    print("Plik nie został znaleziony. Sprawdź ścieżkę.")
except pd.errors.EmptyDataError:
    print("Plik jest pusty.")
except Exception as e:
    print(f"Wystąpił błąd: {e}")
```

Dane zostały pomyślnie wczytane.

	age	sex	bmi	children	smoker	region	expenses
0	19	female	27.9	0	yes	southwest	16884.92
1	18	male	33.8	1	no	southeast	1725.55
2	28	male	33.0	3	no	southeast	4449.46
3	33	male	22.7	0	no	northwest	21984.47
4	32	male	28.9	0	no	northwest	3866.86

```
data.isna().sum()
```

```
age      0
sex      0
bmi      0
children 0
smoker   0
region   0
expenses 0
dtype: int64
```

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   age         1338 non-null   int64
1   sex         1338 non-null   object
2   bmi         1338 non-null   float64
3   children    1338 non-null   int64
4   smoker      1338 non-null   object
5   region      1338 non-null   object
6   expenses    1338 non-null   float64
dtypes: float64(2), int64(2), object(3)
memory usage: 73.3+ KB
```

```
data.describe()
```

	age	bmi	children	expenses
count	1338.000000	1338.000000	1338.000000	1338.000000
mean	39.207025	30.665471	1.094918	13270.422414
std	14.049960	6.098382	1.205493	12110.011240
min	18.000000	16.000000	0.000000	1121.870000
25%	27.000000	26.300000	0.000000	4740.287500
50%	39.000000	30.400000	1.000000	9382.030000
75%	51.000000	34.700000	2.000000	16639.915000
max	64.000000	53.100000	5.000000	63770.430000

```
# Dodanie kolumny z ID klienta na początku tabeli
```

```
data.insert(0, 'ID', range(1, len(data) + 1))
```

```
print(data.head())
```

	ID	age	sex	bmi	children	smoker	region	expenses
0	1	19	female	27.9	0	yes	southwest	16884.92
1	2	18	male	33.8	1	no	southeast	1725.55
2	3	28	male	33.0	3	no	southeast	4449.46
3	4	33	male	22.7	0	no	northwest	21984.47
4	5	32	male	28.9	0	no	northwest	3866.86

```
# Tworzenie wykresu punktowego wydatków
```

```
plt.figure(figsize=(12, 8))
```

```
plt.scatter(data['ID'], data['expenses'], color='blue', alpha=0.7)
```


```
#plt.title('Wykres punktowy wydatków', fontsize=16)
```

```
plt.xlabel('ID klienta', fontsize=14)
```

```
plt.ylabel('Wydatki', fontsize=14)
```


```
plt.grid(True, linestyle='--', alpha=0.5)
```

```
plt.show()
```




```
# Obliczenie średnich wydatków dla każdego wieku
srednie_wydatki = data.groupby('age')['expenses'].mean()


# Rysowanie wykresu punktowego
plt.figure(figsize=(12, 8))
plt.scatter(srednie_wydatki.index, srednie_wydatki.values,
            color='blue', alpha=0.7, label='Średnie wydatki')
# plt.title('Średnie wydatki na ubezpieczenia zależności od wieku')
plt.xlabel('Wiek')
plt.ylabel('Średnie wydatki')
plt.grid(alpha=0.3)
plt.legend()
plt.show()
```




```
# Tworzenie histogramu wydatków
plt.figure(figsize=(12, 8))
plt.hist(data['expenses'], bins=50, color='blue', edgecolor='black',
alpha=0.7)
#plt.title('Histogram wydatków', fontsize=16)
plt.xlabel('Wydatki', fontsize=14)
plt.ylabel('Częstość', fontsize=14)
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```



```
# Wykres gęstości wydatków
plt.figure(figsize=(12, 8))
sns.kdeplot(data['expenses'])
#plt.title("Wykres gęstości wydatków")
plt.xlabel("Wydatki")
plt.ylabel("Gęstość")
plt.show()
```



```
# Wykres gęstości wydatków po zlogarytmowanie danych
plt.figure(figsize=(12, 8))
sns.kdeplot(np.log(data['expenses']))
#plt.title("Wykres gęstości wydatków po zlogarytmowaniu danych")
plt.xlabel("Wydatki")
plt.ylabel("Gęstość")
plt.show()
```



```
wydatki=data["expenses"]

# Poziomy ufności
confidence_level_95 = 0.95
confidence_level_99 = 0.99

mu = np.mean(wydatki)
print("Średnia wydatków: ", mu)
sigma = np.std(wydatki)
print("Odchylenie standardowe: ", sigma)

# Metoda wariancji-kowariancji dla rozkładu logarytmiczno-normalnego
log_data = np.log(wydatki) # Logarytmowanie danych
mu = np.mean(log_data)
print("Średnia wydatków po zlogarytmowaniu: ", mu)
sigma = np.std(log_data)
print("Odchylenie standardowe po zlogarytmowaniu: ", sigma)
VaR_cov_95 = np.exp(mu - stats.norm.ppf(confidence_level_95) * sigma)
VaR_cov_99 = np.exp(mu - stats.norm.ppf(confidence_level_99) * sigma)

# Wyświetlenie wyników
print(f"Value at risk metodą wariancji-kowariancji:")
print(f"  VaR 95%: {VaR_cov_95:.2f}")
print(f"  VaR 99%: {VaR_cov_99:.2f}")
```

```


# Tworzenie wykresu
plt.figure(figsize=(12, 8))
plt.hist(wydatki, bins=50, alpha=0.6, label="Wydatki", density=True)
x = np.linspace(min(wydatki), max(wydatki), 1000)
pdf = stats.lognorm.pdf(x, s=sigma, scale=np.exp(mu))
sns.kdeplot(data['expenses'], color='blue', label="Gęstość wydatków")
plt.plot(x, pdf, 'orange', label="Gęstość rozkładu log-normalnego")
plt.axvline(VaR_cov_95, color='green', linestyle='dashed',
linewidth=2, label=f"VaR 95%: {VaR_cov_95:.2f}")
plt.axvline(VaR_cov_99, color='red', linestyle='dashed', linewidth=2,
label=f"VaR 99%: {VaR_cov_99:.2f}")
plt.xlim(0, 66000)
#plt.title("Value at Risk metodą wariancji-kowariancji dla rozkładu
logarytmiczno normalnego")
plt.xlabel("Wydatki")
plt.ylabel("Gęstość")
plt.legend()
plt.show()

```

```

Średnia wydatków: 13270.422414050823
Odchylenie standardowe: 12105.484978572953
Średnia wydatków po zlogarytmowaniu: 9.098658755216183
Odchylenie standardowe po zlogarytmowaniu: 0.9191834027815341
Value at risk metodą wariancji-kowariancji:
    VaR 95%: 1971.87
    VaR 99%: 1053.97

```

```
skewness = skew(wydatki)
kurtosis_value = kurtosis(wydatki)
print(skewness)
print(kurtosis_value)

1.5141797167430497
1.5958213684180036

gamma_params = gamma.fit(wydatki)
lognorm_params = lognorm.fit(wydatki)

# Test dla gamma
ks_gamma = kstest(wydatki, "gamma", args=gamma_params)
print(ks_gamma)

# Test dla log-normalnego
ks_lognorm = kstest(wydatki, "lognorm", args=lognorm_params)
print(ks_lognorm)

KstestResult(statistic=0.06018338547487834,
pvalue=0.00011788509097231956, statistic_location=14478.33,
statistic_sign=1)
KstestResult(statistic=0.038368057655881416,
```

```
pvalue=0.0379136806908239, statistic_location=8211.1, statistic_sign=-1)
```

```
# Poziomy ufności
```

```
confidence_level_95 = 0.95
```

```
confidence_level_99 = 0.99
```

```
# Metoda historyczna
```

```
sorted_data = np.sort(wydatki)
```

```
VaR_hist_95 = sorted_data[int((1 - confidence_level_95) *  
len(sorted_data))]
```

```
VaR_hist_99 = sorted_data[int((1 - confidence_level_99) *  
len(sorted_data))]
```

```
# Wyświetlanie wyników
```

```
print(f"Value at risk metodą historyczną:")
```

```
print(f"  VaR 95%: {VaR_hist_95:.2f}")
```

```
print(f"  VaR 99%: {VaR_hist_99:.2f}")
```

```
# Tworzenie wykresu
```

```
plt.figure(figsize=(12, 8))
```

```
plt.hist(wydatki, bins=50, alpha=0.6, label="Wydatki", density=True)
```

```
sns.kdeplot(data['expenses'], color="blue", label="Gęstość wydatków")
```

```
plt.axvline(VaR_hist_95, color='green', linestyle='dashed',
```

```
linewidth=2, label=f"VaR 95%: {VaR_hist_95:.2f}")
```

```
plt.axvline(VaR_hist_99, color='red', linestyle='dashed', linewidth=2,  
label=f"VaR 99%: {VaR_hist_99:.2f}")
```

```
plt.xlim(0, 66000)
```

```
#plt.title("Value at Risk metodą historyczną")
```

```
plt.xlabel("Wydatki")
```

```
plt.ylabel("Gęstość")
```


```
plt.legend()
```

```
plt.show()
```

```
Value at risk metodą historyczną:
```

```
  VaR 95%: 1748.77
```

```
  VaR 99%: 1252.41
```



```
# Poziomy ufności
confidence_level_95 = 0.95
confidence_level_99 = 0.99

# Symulacja Monte Carlo
log_data = np.log(wydatki) # Logarytmowanie danych
mu = np.mean(log_data)
sigma = np.std(log_data)
n_simulations = 10000
simulated_data = np.random.lognormal(mu, sigma, n_simulations)
VaR_mc_95 = np.percentile(simulated_data, (1 - confidence_level_95) *
100)
VaR_mc_99 = np.percentile(simulated_data, (1 - confidence_level_99) *
100)

# Wyświetlenie wyników
print(f"Value at risk metodą symulacji Monte Carlo:")
print(f"  VaR 95%: {VaR_mc_95:.2f}")
print(f"  VaR 99%: {VaR_mc_99:.2f}")

# Wizualizacja danych historycznych i Monte Carlo
plt.figure(figsize=(12, 8))
plt.hist(wydatki, bins=50, alpha=0.5, label="Wydatki", density=True)
```

```


plt.hist(simulated_data, bins=200, color="orange", alpha=0.5,
label="Wydatki z symulacji Monte Carlo", density=True)
sns.kdeplot(data['expenses'], color="blue", label="Gęstość wydatków")
sns.kdeplot(simulated_data, color="darkorange", label="Gęstość
wydatków z symulacji")
plt.axvline(VaR_mc_95, color='green', linestyle='dashed', linewidth=2,
label=f"VaR 95%: {VaR_mc_95:.2f}")
plt.axvline(VaR_mc_99, color='red', linestyle='dashed', linewidth=2,
label=f"VaR 99%: {VaR_mc_99:.2f}")
plt.xlim(0, 80000)
#plt.title("Value at risk metodą symulacji Monte Carlo")
plt.xlabel("Wydatki")
plt.ylabel("Gęstość")
plt.legend()
plt.show()

```

Value at risk metodą symulacji Monte Carlo:

VaR 95%: 1968.02

VaR 99%: 1103.04



2 Plik

```
# Ścieżka do pliku CSV
file_path = "C:/Users/Lukasz/Desktop/studia/Semestr
7/Motor_insurance.csv"

# Wczytywanie danych z pliku CSV
try:
    dane = pd.read_csv(file_path, delimiter=';')
    print("Dane zostały pomyślnie wczytane.")
    #print(data.head())
except FileNotFoundError:
    print("Plik nie został znaleziony. Sprawdź ścieżkę.")
except pd.errors.EmptyDataError:
    print("Plik jest pusty.")
except Exception as e:
    print(f"Wystąpił błąd: {e}")

Dane zostały pomyślnie wczytane.

# Transpozycja danych
dane_transposed = dane.transpose()
print(dane_transposed)
```

	0	1	2	
3				
ID	1	1	1	1
Date_start_contract	05/11/2015	05/11/2015	05/11/2015	05/11/2015
Date_last_renewal	05/11/2015	05/11/2016	05/11/2017	05/11/2018
Date_next_renewal	05/11/2016	05/11/2017	05/11/2018	05/11/2019
Date_birth	15/04/1956	15/04/1956	15/04/1956	15/04/1956
Date_driving_licence	20/03/1976	20/03/1976	20/03/1976	20/03/1976
Distribution_channel	0	0	0	0
Seniority	4	4	4	4
Policies_in_force	1	1	2	2
Max_policies	2	2	2	2
Max_products	1	1	1	1
Lapse	0	0	0	0
Date_lapse	NaN	NaN	NaN	NaN

Payment	0	0	0	0
Premium	222.52	213.78	214.84	216.99
Cost_claims_year	0.0	0.0	0.0	0.0
N_claims_year	0	0	0	0
N_claims_history	0	0	0	0
R_Claims_history	0.0	0.0	0.0	0.0
Type_risk	1	1	1	1
Area	0	0	0	0
Second_driver	0	0	0	0
Year_matriculation	2004	2004	2004	2004
Power	80	80	80	80
Cylinder_capacity	599	599	599	599
Value_vehicle	7068.0	7068.0	7068.0	7068.0
N_doors	0	0	0	0
Type_fuel	P	P	P	P
Length	NaN	NaN	NaN	NaN
Weight	190	190	190	190
	4	5	6	
7 \				
ID	2	2	3	3
Date_start_contract	26/09/2017	26/09/2017	29/11/2013	29/11/2013
Date_last_renewal	26/09/2017	26/09/2018	29/11/2015	29/11/2016
Date_next_renewal	26/09/2018	26/09/2019	29/11/2016	29/11/2017
Date_birth	15/04/1956	15/04/1956	18/03/1975	18/03/1975
Date_driving_licence	20/03/1976	20/03/1976	10/07/1995	10/07/1995
Distribution_channel	0	0	0	0

Seniority	4	4	15	15
Policies_in_force	2	2	1	1
Max_policies	2	2	2	2
Max_products	1	1	1	1
Lapse	0	0	0	0
Date_lapse	NaN	NaN	NaN	NaN
Payment	1	1	0	0
Premium	213.7	215.83	380.2	393.5
Cost_claims_year	0.0	0.0	0.0	0.0
N_claims_year	0	0	0	0
N_claims_history	0	0	0	0
R_Claims_history	0.0	0.0	0.0	0.0
Type_risk	1	1	3	3
Area	0	0	0	0
Second_driver	0	0	0	0
Year_matriculation	2004	2004	2013	2013
Power	80	80	85	85
Cylinder_capacity	599	599	1229	1229
Value_vehicle	7068.0	7068.0	16030.0	16030.0
N_doors	0	0	5	5
Type_fuel	P	P	P	P
Length	NaN	NaN	3.999	3.999
Weight	190	190	1105	1105
	8	9	...	105545
105546 \				
ID	3	3	...	53493
53494				

Date_start_contract	29/11/2013	29/11/2013	...	26/10/2018
02/07/2018				
Date_last_renewal	29/11/2017	29/11/2018	...	26/10/2018
02/07/2018				
Date_next_renewal	29/11/2018	29/11/2019	...	26/10/2019
02/07/2019				
Date_birth	18/03/1975	18/03/1975	...	24/07/1977
02/11/1955				
Date_driving_licence	10/07/1995	10/07/1995	...	27/05/2015
04/01/1974				
Distribution_channel	0	0	...	1
0				
Seniority	15	15	...	1
1				
Policies_in_force	1	1	...	1
1				
Max_policies	2	2	...	1
1				
Max_products	1	1	...	1
1				
Lapse	0	0	...	0
0				
Date_lapse	NaN	NaN	...	NaN
NaN				
Payment	0	0	...	0
0				
Premium	393.5	395.47	...	191.15
430.08				
Cost_claims_year	0.0	0.0	...	0.0
0.0				
N_claims_year	0	0	...	0
0				
N_claims_history	0	0	...	0
0				
R_Claims_history	0.0	0.0	...	0.0
0.0				
Type_risk	3	3	...	1
3				
Area	0	0	...	1
0				
Second_driver	0	0	...	0
1				
Year_matriculation	2013	2013	...	2017
2018				
Power	85	85	...	32
100				
Cylinder_capacity	1229	1229	...	395
1390				
Value_vehicle	16030.0	16030.0	...	6999.0

17920.0				
N_doors	5	5	...	0
5				
Type_fuel	P	P	...	P
P				
Length	3.999	3.999	...	NaN
4.209				
Weight	1105	1105	...	213
1165				
	105547	105548	105549	
105550 \				
ID	53495	53496	53497	53498
Date_start_contract	06/07/2018	11/09/2018	10/11/2018	30/07/2018
Date_last_renewal	06/07/2018	11/09/2018	10/11/2018	30/07/2018
Date_next_renewal	06/07/2019	11/09/2019	10/11/2019	30/07/2019
Date_birth	29/12/1992	26/07/1984	29/06/1961	25/07/1981
Date_driving_licence	23/10/2014	28/04/2017	28/12/1990	14/02/2007
Distribution_channel	0	0	0	0
Seniority	1	1	1	1
Policies_in_force	1	1	1	1
Max_policies	1	1	1	1
Max_products	1	1	1	1
Lapse	0	0	0	0
Date_lapse	NaN	NaN	NaN	NaN
Payment	1	0	0	0
Premium	370.3	253.94	233.22	263.79
Cost_claims_year	0.0	0.0	0.0	0.0
N_claims_year	0	0	0	0
N_claims_history	0	0	0	0
R_Claims_history	0.0	0.0	0.0	0.0
Type_risk	3	3	2	3

Area	0	0	0	0
Second_driver	0	0	0	0
Year_matriculation	1998	1998	2017	2000
Power	83	11	75	110
Cylinder_capacity	1998	505	1968	1997
Value_vehicle	18613.34	10217.21	21761.85	24320.0
N_doors	5	3	5	5
Type_fuel	D	P	D	D
Length	4.245	NaN	4.408	4.74
Weight	1470	400	1564	1480
ID	105551 53499	105552 53500	105553 53501	105554 53502
Date_start_contract	16/08/2018	21/11/2018	21/11/2018	01/10/2018
Date_last_renewal	16/08/2018	21/11/2018	21/11/2018	01/10/2018
Date_next_renewal	16/08/2019	21/11/2019	21/11/2019	01/10/2019
Date_birth	08/12/1976	01/04/1974	15/09/1946	09/05/1973
Date_driving_licence	29/11/2017	05/10/2011	02/02/1982	30/09/1991
Distribution_channel	0	0	0	1
Seniority	1	1	1	1
Policies_in_force	1	1	1	1
Max_policies	1	1	1	1
Max_products	1	1	1	1
Lapse	0	0	0	0
Date_lapse	NaN	NaN	NaN	NaN
Payment	0	1	0	0
Premium	418.97	571.91	339.66	447.12
Cost_claims_year	0.0	0.0	0.0	0.0
N_claims_year	0	0	0	0
N_claims_history	0	0	0	0
R_Claims_history	0.0	0.0	0.0	0.0
Type_risk	3	3	2	3
Area	0	0	0	0
Second_driver	0	0	0	0
Year_matriculation	2013	1999	2004	2010
Power	129	55	90	140
Cylinder_capacity	1998	999	1753	1968
Value_vehicle	30861.97	7800.0	16610.0	33400.0
N_doors	5	5	5	5
Type_fuel	P	P	D	D

Length	4.65	3.495	4.555	4.854
Weight	1440	830	1399	1699

[30 rows x 105555 columns]

dane.describe()

	ID	Distribution_channel	Seniority
Policies_in_force \			
count	105555.000000	105555.000000	105555.000000
105555.000000			
mean	26271.286789	0.451310	6.696604
1.455649			
std	15388.309324	0.497626	6.263911
0.928427			
min	1.000000	0.000000	1.000000
1.000000			
25%	12925.000000	0.000000	3.000000
1.000000			
50%	26082.000000	0.000000	4.000000
1.000000			
75%	39754.000000	1.000000	9.000000
2.000000			
max	53502.000000	1.000000	40.000000
17.000000			

	Max_policies	Max_products	Lapse	Payment \
count	105555.000000	105555.000000	105555.000000	105555.000000
mean	1.837232	1.065842	0.221837	0.319180
std	1.155536	0.267807	0.464858	0.466161
min	1.000000	1.000000	0.000000	0.000000
25%	1.000000	1.000000	0.000000	0.000000
50%	2.000000	1.000000	0.000000	0.000000
75%	2.000000	1.000000	0.000000	1.000000
max	17.000000	4.000000	7.000000	1.000000

	Premium	Cost_claims_year	...	Type_risk
Area \				
count	105555.000000	105555.000000	...	105555.000000
105555.000000				
mean	315.892557	153.557305	...	2.721804
0.273895				
std	140.927969	1477.112362	...	0.614835
0.445958				
min	40.140000	0.000000	...	1.000000
0.000000				
25%	241.610000	0.000000	...	3.000000
0.000000				
50%	292.280000	0.000000	...	3.000000
0.000000				

```

75%      361.640000      0.000000 ...      3.000000
1.000000
max      2993.340000      260853.240000 ...      4.000000
1.000000

```

```

      Second_driver  Year_matriculation      Power
Cylinder_capacity \
count 105555.000000      105555.000000 105555.000000
105555.000000
mean      0.123708      2004.728038      92.682611
1617.759367
std      0.329250      6.767037      37.012645
604.697382
min      0.000000      1950.000000      0.000000
49.000000
25%      0.000000      2001.000000      75.000000
1390.000000
50%      0.000000      2005.000000      90.000000
1598.000000
75%      0.000000      2008.000000      110.000000
1910.000000
max      1.000000      2018.000000      580.000000
7480.000000

```

```

      Value_vehicle      N_doors      Length      Weight
count 105555.000000 105555.000000 95226.000000 105555.000000
mean  18413.657243      4.067898      4.252007      1191.262422
std   9135.074235      1.511839      0.393220      458.081834
min   270.460000      0.000000      1.978000      43.000000
25%   13127.210000      3.000000      3.999000      1043.000000
50%   17608.770000      5.000000      4.230000      1205.000000
75%   22595.000000      5.000000      4.443000      1388.000000
max   220675.800000      6.000000      8.218000      7300.000000

```

```
[8 rows x 23 columns]
```

```
dane.isna().sum()
```

```

ID      0
Date_start_contract  0
Date_last_renewal    0
Date_next_renewal    0
Date_birth            0
Date_driving_licence  0
Distribution_channel  0
Seniority             0
Policies_in_force     0
Max_policies           0
Max_products           0
Lapse                 0

```

```

Date_lapse          70408
Payment             0
Premium             0
Cost_claims_year    0
N_claims_year       0
N_claims_history    0
R_Claims_history    0
Type_risk           0
Area               0
Second_driver       0
Year_matriculation  0
Power              0
Cylinder_capacity   0
Value_vehicle       0
N_doors             0
Type_fuel           1764
Length             10329
Weight              0
dtype: int64

```

```
dane.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 105555 entries, 0 to 105554
Data columns (total 30 columns):

```

#	Column	Non-Null Count	Dtype
0	ID	105555 non-null	int64
1	Date_start_contract	105555 non-null	object
2	Date_last_renewal	105555 non-null	object
3	Date_next_renewal	105555 non-null	object
4	Date_birth	105555 non-null	object
5	Date_driving_licence	105555 non-null	object
6	Distribution_channel	105555 non-null	int64
7	Seniority	105555 non-null	int64
8	Policies_in_force	105555 non-null	int64
9	Max_policies	105555 non-null	int64
10	Max_products	105555 non-null	int64
11	Lapse	105555 non-null	int64
12	Date_lapse	35147 non-null	object
13	Payment	105555 non-null	int64
14	Premium	105555 non-null	float64
15	Cost_claims_year	105555 non-null	float64
16	N_claims_year	105555 non-null	int64
17	N_claims_history	105555 non-null	int64
18	R_Claims_history	105555 non-null	float64
19	Type_risk	105555 non-null	int64
20	Area	105555 non-null	int64
21	Second_driver	105555 non-null	int64
22	Year_matriculation	105555 non-null	int64

```


23 Power                105555 non-null int64
24 Cylinder_capacity     105555 non-null int64
25 Value_vehicle        105555 non-null float64
26 N_doors              105555 non-null int64
27 Type_fuel            103791 non-null object
28 Length               95226 non-null float64
29 Weight               105555 non-null int64
dtypes: float64(5), int64(18), object(7)
memory usage: 24.2+ MB

```

```

# Tworzenie wykresu punktowego wydatków
plt.figure(figsize=(12, 8))
plt.scatter(dane['ID'], dane['Premium'], color='blue', alpha=0.7)
#plt.title('Wykres punktowy wydatków', fontsize=16)
plt.xlabel('ID', fontsize=14)
plt.ylabel('Składka', fontsize=14)
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()

```




```


# Tworzenie histogramu wydatków
plt.figure(figsize=(12, 8))
plt.hist(dane['Premium'], bins=120, color='blue', edgecolor='black',
alpha=0.7)
#plt.title('Histogram wydatków', fontsize=16)

```


```
plt.xlabel('Składka', fontsize=14)
plt.ylabel('Częstość', fontsize=14)
plt.xlim(0, 1500)
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```



```
# Wykres gęstości wydatków
plt.figure(figsize=(12, 8))
sns.kdeplot(dane['Premium'])
#plt.title("Wykres gęstości wydatków")
plt.xlim(0, 1500)
plt.xlabel("Składka")
plt.ylabel("Gęstość")
plt.show()
```



```
# Wykres gęstości wydatków po zlogarytmowanie danych
plt.figure(figsize=(12, 8))
sns.kdeplot(np.log(dane['Premium']))
#plt.title("Wykres gęstości wydatków po zlogarytmowaniu danych")
plt.xlabel("Składka")
plt.ylabel("Gęstość")
plt.show()
```

```
skewness = skew(dane["Premium"])
kurtosis_value = kurtosis(dane["Premium"])
print(skewness)
print(kurtosis_value)

2.2178373668773097
13.00130872114035

gamma_params = gamma.fit(dane["Premium"])
lognorm_params = lognorm.fit(dane["Premium"])

# Test dla gamma
ks_gamma = kstest(dane["Premium"], "gamma", args=gamma_params)
print(ks_gamma)

# Test dla log-normalnego
ks_lognorm = kstest(dane["Premium"], "lognorm", args=lognorm_params)
print(ks_lognorm)

KstestResult(statistic=0.9946231717176501, pvalue=0.0,
statistic_location=49.39, statistic_sign=-1)
KstestResult(statistic=0.07714862799054975, pvalue=0.0,
statistic_location=220.49, statistic_sign=-1)
```

```

premium=dane["Premium"]

# Poziomy ufności
confidence_level_95 = 0.95
confidence_level_99 = 0.99

mu = np.mean(premium)
print("Średnia wydatków: ", mu)
sigma = np.std(premium)
print("Odchylenie standardowe: ", sigma)

# Metoda wariancji-kowariancji dla rozkładu logarytmiczno-normalnego
log_dane = np.log(premium) # Logarytmowanie danych
mu = np.mean(log_dane)
print("Średnia wydatków po zlogarytmowaniu: ", mu)
sigma = np.std(log_dane)
print("Odchylenie standardowe po zlogarytmowaniu: ", sigma)
VaR_cov_95 = np.exp(mu - stats.norm.ppf(confidence_level_95) * sigma)
VaR_cov_99 = np.exp(mu - stats.norm.ppf(confidence_level_99) * sigma)

# Wyświetlenie wyników
print(f"Value at risk metodą wariancji-kowariancji:")
print(f" VaR 95%: {VaR_cov_95:.2f}")
print(f" VaR 99%: {VaR_cov_99:.2f}")

# Tworzenie wykresu
plt.figure(figsize=(12, 8))
plt.hist(premium, bins=120, alpha=0.6, label="Składka", density=True)
x = np.linspace(min(premium), max(premium), 1000)
pdf = stats.lognorm.pdf(x, s=sigma, scale=np.exp(mu))
sns.kdeplot(dane['Premium'], color='blue', label="Gęstość składki")
plt.plot(x, pdf, 'orange', label="Gęstość rozkładu log-normalnego")
plt.axvline(VaR_cov_95, color='green', linestyle='dashed',
linewidth=2, label=f"VaR 95%: {VaR_cov_95:.2f}")
plt.axvline(VaR_cov_99, color='red', linestyle='dashed', linewidth=2,
label=f"VaR 99%: {VaR_cov_99:.2f}")
plt.xlim(0, 1500)
#plt.title("Value at Risk metodą wariancji-kowariancji dla rozkładu
logarytmiczno normalnego")
plt.xlabel("Składka")
plt.ylabel("Gęstość")
plt.legend()
plt.show()

```

Średnia wydatków: 315.8925572450381


Odchylenie standardowe: 140.92730136619994

Średnia wydatków po zlogarytmowaniu: 5.663791981345274

Odchylenie standardowe po zlogarytmowaniu: 0.4437915110313584

Value at risk metodą wariancji-kowariancji:

VaR 95%: 138.91
VaR 99%: 102.66



```
# Poziomy ufności
confidence_level_95 = 0.95
confidence_level_99 = 0.99

# Metoda historyczna
sorted_dane = np.sort(premium)
VaR_hist_95 = sorted_dane[int((1 - confidence_level_95) *
len(sorted_dane))]
VaR_hist_99 = sorted_dane[int((1 - confidence_level_99) *
len(sorted_dane))]

# Wyświetlanie wyników
print(f"Value at risk metodą historyczną:")
print(f"  VaR 95%: {VaR_hist_95:.2f}")
print(f"  VaR 99%: {VaR_hist_99:.2f}")

# Tworzenie wykresu
plt.figure(figsize=(12, 8))
plt.hist(premium, bins=100, alpha=0.6, label="Składka", density=True)
sns.kdeplot(dane['Premium'], color="blue", label="Gęstość składki")
plt.axvline(VaR_hist_95, color='green', linestyle='dashed',
```

```


linewidth=2, label=f"VaR 95%: {VaR_hist_95:.2f}")
plt.axvline(VaR_hist_99, color='red', linestyle='dashed', linewidth=2,
label=f"VaR 99%: {VaR_hist_99:.2f}")
plt.xlim(0, 1500)
#plt.title("Value at Risk metodą historyczną")
plt.xlabel("Składka")
plt.ylabel("Gęstość")
plt.legend()
plt.show()

```

Value at risk metodą historyczną:

VaR 95%: 122.40

VaR 99%: 64.35



```

# Poziomy ufności
confidence_level_95 = 0.95
confidence_level_99 = 0.99

# Symulacja Monte Carlo
log_dane = np.log(premium) # Logarytmowanie danych
mu = np.mean(log_dane)
sigma = np.std(log_dane)
n_simulations = 10000
simulated_dane = np.random.lognormal(mu, sigma, n_simulations)

```

```

VaR_mc_95 = np.percentile(simulated_dane, (1 - confidence_level_95) *
100)
VaR_mc_99 = np.percentile(simulated_dane, (1 - confidence_level_99) *
100)

# Wyświetlenie wyników
print(f"Value at risk metodą symulacji Monte Carlo:")
print(f"  VaR 95%: {VaR_mc_95:.2f}")
print(f"  VaR 99%: {VaR_mc_99:.2f}")

# Wizualizacja danych historycznych i Monte Carlo
plt.figure(figsize=(12, 8))
plt.hist(premium, bins=100, alpha=0.5, label="Składka", density=True)
plt.hist(simulated_dane, bins=50, color="orange", alpha=0.5,
label="Składki z symulacji Monte Carlo", density=True)
sns.kdeplot(dane['Premium'], color="blue", label="Gęstość składek")
sns.kdeplot(simulated_dane, color="darkorange", label="Gęstość składek
z symulacji")
plt.axvline(VaR_mc_95, color='green', linestyle='dashed', linewidth=2,
label=f"VaR 95%: {VaR_mc_95:.2f}")
plt.axvline(VaR_mc_99, color='red', linestyle='dashed', linewidth=2,
label=f"VaR 99%: {VaR_mc_99:.2f}")
plt.xlim(0, 1500)
#plt.title("Value at risk metodą symulacji Monte Carlo")
plt.xlabel("Składki")
plt.ylabel("Gęstość")
plt.legend()
plt.show()

```

```

Value at risk metodą symulacji Monte Carlo:
  VaR 95%: 140.14
  VaR 99%: 103.93

```

